

1.1 排列与组合

1.1.1 排列

从 n 个不同元素中任取 r ($r \leq n$) 个元素排成一排 (不能重复选择元素, 要考虑元素的先后顺序), 称为一个排列 (Permutation)。按乘法原理, 此种排列共有

$$n \times (n-1) \times \cdots \times (n-r+1)$$

种, 记作 P_n^r , 可以读作:

$$n \text{ Pick } r$$

若 $r = n$, 称为全排列, 全排列数共有 $n!$ 个, 记为 P_n 。

1.1.2 组合

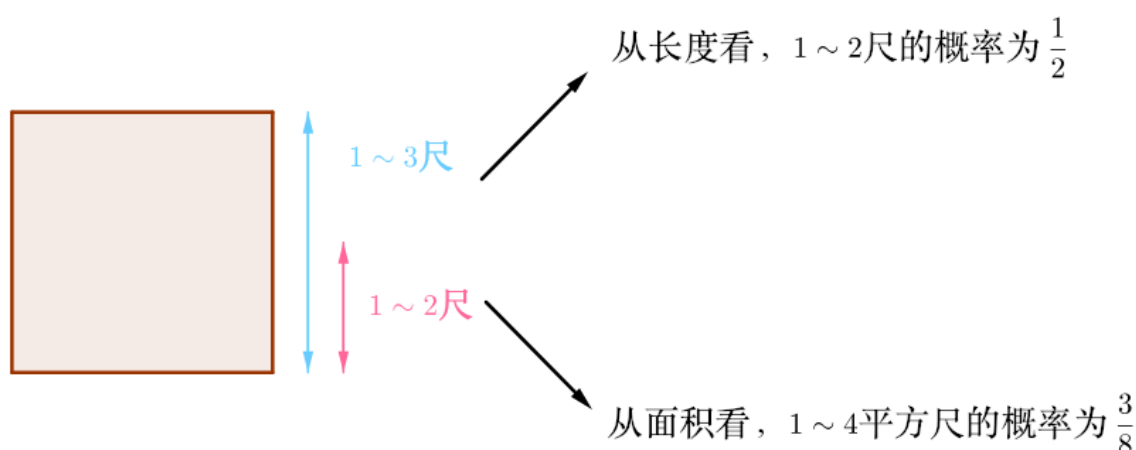
从 n 个不同元素中任取 r ($r \leq n$) 个元素并成一组(不区分顺序), 称为一个组合 (Combination), 组合总数为:

$$C_n^r = \binom{n}{r} = \frac{P_n^r}{r!} = \frac{n!}{r!(n-r)!}$$

可以读作:

$$n \text{ Choose } r$$

1.3 几何概型



通过这个典型的例子可以看到, 样本空间选择不同, 同一个问题会得到不同的概率。值得注意的是, 就数学而言, 这两个结论都是对的; 在现实中哪个是对的, 还需要通过采样、测量来决定。

1.2 事件的关系与运算

1.2.1 关系

| | |
|----|-----------------------------------|
| 包含 | $A \subseteq B$ 或 $B \subseteq A$ |
| 相等 | $A \subseteq B$ 且 $B \subseteq A$ |
| 互斥 | $A \cap B = \emptyset$ |
| 对立 | $A = \bar{B}$ |

1.2.1.1 包含

设 A 、 B 为两个事件，若 $A \subseteq B$ ，则可推出：

$$P(B - A) = P(B) - P(A) \quad (1)$$

$$P(A) \leq P(B) \quad (2)$$

1.2.1.2 加法公式

对于任意两个事件，有：

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

也常写作如下的形式：

$$P(A + B) = P(A) + P(B) - P(AB)$$

所以这个公式也称为概率的**加法公式**。

两个事件加法公式也可以推广至三个事件：

$$P(A \cup B \cup C) = P(A) + P(B) + P(C)$$

$$\underbrace{-P(A \cap B) - P(A \cap C) - P(B \cap C)}_{\text{重复计算的部分需要“排斥”出去}}$$

$$\underbrace{+P(A \cap B \cap C)}_{\text{多“排斥”出去的部分需要“包容”回来}}$$

所以，加法公式也被称作**容斥定理** (Inclusion-exclusion principle) 。

1.2.2 运算

| | 定义 | 类比 |
|---|---|----------|
| 并 | $A \cup B = \{x x \in A \text{ 或 } x \in B\}$ | + |
| 交 | $A \cap B = \{x x \in A \text{ 且 } x \in B\}$ | \times |
| 差 | $A - B = \{x x \in A \text{ 且 } x \notin B\}$ | - |
| 补 | $\overline{A} = B \iff B = \Omega - A$ | |

然后这些基本运算和实数基本运算的性质差不多。

1.2.2.1 交换律

- $A + B = B + A$
- $AB = BA$

1.2.2.2 结合律

- $A + B + C = A + (B + C)$
- $ABC = A(BC)$

1.2.2.3 分配律

- $(A + B)C = AC + BC$
- $(A - B)C = AC - BC$
- $(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$

1.2.2.4 德摩根定律

- $\overline{A \cup B} = \overline{A} \cap \overline{B}$
- $\overline{A \cap B} = \overline{A} \cup \overline{B}$

1.2 条件概率

1.2.1 定义

设 A 和 B 是样本空间 Ω 中的两事件，若 $P(B) > 0$ ，则称：

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

为“假设条件为 B 时的 A 的概率”，简称 **条件概率**。也常写作：

$$P(A|B) = \frac{P(AB)}{P(B)}$$

概率与条件概率两者最重要的区别是：

- $P(A)$ 是以 Ω 为样本空间，这是一个全局的空间，包含所有可能性
- $P(A|B)$ 是以 B 为样本空间，相对而言是一个局部空间，有些可能性被排除掉了

1.2.2 性质

条件概率虽然是被推广出来的定义，但这种推广也是很合理的，一方面符合过往的经验（可以用古典派进行验算），另外一方面符合概率三大公理：

对于条件概率 $P(A|B)$ ，满足以下三大公理：

(1) 非负性公理：

$$P(A|B) \geq 0$$

(2) 规范性公理：

$$P(\Omega|B) = 1$$

(3) 可加性公理：设 A_1 、 A_2 、 \dots 为两两不相容的事件，即 $A_i \cap A_j = \emptyset$ ($i \neq j$)，有：

$$P\left(\bigcup_{n=1}^{\infty} A_n|B\right) = \sum_{n=1}^{\infty} P(A_n|B)$$

证明了条件概率是数学意义上的概率之后，马上就知道了，之前所做的推论在条件概率上也成立：

| | 概率 | 条件概率 |
|-------------------------|--|--|
| 空集 | $P(\emptyset) = 0$ | $P(\emptyset C) = 0$ |
| 包含 $(A \subseteq B)$ | $P(B - A) = P(B) - P(A)$ $P(A) \leq P(B)$ | $P(B - A C) = P(B C) - P(A C)$ $P(A C) \leq P(B C)$ |
| 加法 | $P(A + B) = P(A) + P(B)$ $- P(AB)$ | $P(A + B C) = P(A C) + P(B C)$ $- P(AB C)$ |

这里也可看出把概率公理化的好处，从很简单的三个公理开始，对各种结论进行证明。反过来，如果某定义满足这三个公理，那么概率论中的所有结论都对它成立。

1.2.3 乘法公式

从条件概率的定义我们马上可以推出乘法公式：

(1) 若 $P(B) > 0$ ，则：

$$P(AB) = P(B)P(A|B)$$

(2) 若 $P(A) > 0$ ，则：

$$P(AB) = P(A)P(B|A)$$

(3) 若 $P(A_1 \cdots A_n) > 0$ ，则：

$$P(A_1 \cdots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 A_2) \cdots P(A_n|A_1 \cdots A_{n-1})$$

查看详细

(3) 式有点难记，其实还是有规律的。也可以手动来推，只需要反复运用条件概率的定义即可：

$$\begin{aligned} P(A_1 A_2 A_3) &= P(A_1 A_2)P(A_3|A_1 A_2) \\ &= P(A_1)P(A_2|A_1)P(A_3|A_1 A_2) \end{aligned}$$

1.2.4 树形图

树形图有助于进一步理解条件概率。


从一道题开始，杯中有三个红球、两个蓝球：




从中随机抽掉一个球后，再抽取一个蓝球的概率有多大？

1 树形图


首先，从中随机抽掉一个球，有 $\frac{3}{5}$ 的可能性抽掉红球、 $\frac{2}{5}$ 的可能性抽掉蓝球：



如果抽掉红球，再抽取一个蓝球的概率为 $\frac{1}{2}$ ：




如果抽掉蓝球，再抽取一个蓝球的概率为 $\frac{1}{4}$ ：




这就是树形图，下面可以用此来解题了。

2 解题

抽掉红球之后，再抽取一个蓝球的概率，可以沿着最上面的支线来计算（高中就是这么计算的，关于这点下一节会详细解释）：



而抽掉蓝球之后，再抽取一个蓝球的概率，可以沿着中间的支线来计算：




这样，随机抽掉一个球后，再抽取一个蓝球的概率是两条直线之和：

$$\frac{3}{10} + \frac{1}{10} = \frac{4}{10}$$

3 验算

如果树形图穷尽了所有的情况，且计算没有出错，那所有的分支概率之和应该为1；如果加起来不为1，说明有错漏，这个特点可以用来验算。来看看本题的所有分支：




所有分支的概率之和确实为1：

$$\frac{3}{10} + \frac{3}{10} + \frac{1}{10} + \frac{3}{10} = 1$$

1.2.4.1 树形图与条件概率

看着刚才那道题的树形图：




把这道题用代数来翻译下：

| | |
|-----------------------------|------------------------|
| 抽掉红球的概率为 $\frac{3}{5}$ | $P(A) = \frac{3}{5}$ |
| 抽掉蓝球的概率为 $\frac{2}{5}$ | $P(B) = \frac{2}{5}$ |
| 抽掉红球后抽取蓝球的概率为 $\frac{1}{2}$ | $P(C A) = \frac{1}{2}$ |
| 抽掉蓝球后抽取蓝球的概率为 $\frac{1}{4}$ | $P(C B) = \frac{1}{4}$ |
| 求，抽取蓝球的概率为多少？ | $P(C) = ?$ |

[查看详细](#)

其实这是一个条件概率的题，把这些概率符号标注到图上：

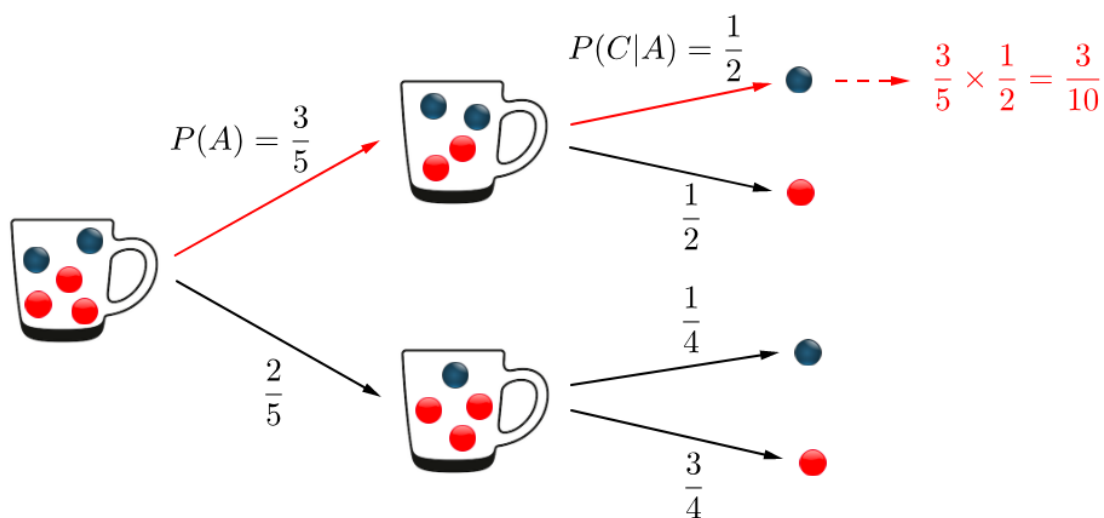


这里也可以看出条件概率的样本空间是局部样本空间：

| 样本空间 | 概率 或 条件概率 |
|--|---|
| $\Omega =$  | $P(A) = \frac{3}{5}$ $P(B) = \frac{2}{5}$ |
| $A =$  | $P(C A) = \frac{1}{2}$ |
| $B =$  | $P(C B) = \frac{1}{4}$ |

1.2.4.2 树形图与乘法公式

刚才求的抽掉红球后，再抽取一个蓝球的概率：



其实就是乘法公式的一次应用：

$$P(AC) = P(A)P(C|A) = \frac{3}{5} \times \frac{1}{2} = \frac{3}{10}$$

例题

1 假设生男、生女的概率均为 $\frac{1}{2}$, 已知一对夫妇有两个孩子, 现在知道他们有一个男孩, 则另一个孩子为女孩的概率为多少

根据古典概率模型, 两个孩子总共有四个等可能的情况:

$$\Omega = \{\text{男女}, \text{男男}, \text{女男}, \text{女女}\}$$

设事件 A 为有一个孩子为女孩, B 为有一个孩子为男孩, 则

$$A = \{\text{男女}, \text{女男}, \text{女女}\}, B = \{\text{男女}, \text{男男}, \text{女男}\}$$

AB 即为有一个男孩一个女孩

$$A \cap B = \{\text{男女}, \text{女男}\}$$

由此可得

$$P(B) = \frac{|B|}{|\Omega|} = \frac{3}{4} \quad P(AB) = \frac{|A \cap B|}{|\Omega|} = \frac{1}{2}$$

在已知一个是男孩的情况下, 根据条件概率

$$P(A|B) = \frac{P(AB)}{P(B)} = \frac{2}{3}$$

2 已知一对夫妇有两个孩子, 现在知道老大为男孩, 则老二为女孩的概率为多少

样本空间 Ω 为:

$$\Omega = \{(\text{男}, \text{女}), (\text{男}, \text{男}), (\text{女}, \text{男}), (\text{女}, \text{女})\}$$

设事件 A = “第一个孩子是男孩”, 事件 B = “第二个孩子是女孩”

$$A = \{(\text{男}, \text{男}), (\text{男}, \text{女})\}, B = \{(\text{男}, \text{女}), (\text{女}, \text{女})\}$$

因此:

$$A \cap B = \{(\text{男}, \text{女})\}$$

根据条件概率:

$$P(B|A) = \frac{P(AB)}{P(A)} = \frac{\frac{|AB|}{|\Omega|}}{\frac{|A|}{|\Omega|}} = \frac{|AB|}{|A|} = \frac{1}{2}$$

3 袋中装有4个黑球, 4个白球, 从中随机取出一个球记下颜色后放回

再往袋中加入与取出的球同色的球2个, 搅拌均匀后按同样的方式去求并加入求, 一共重复三次

求三次中恰好有两次取出的球为黑球的概率 P_2 为

记第 i 次取到黑球为 A_i , 取到白球为 B_i , 其中 $i = 1, 2, 3$, 则

$$P(A_1) = P(A_2) = \frac{1}{2}$$

在第一次取出黑球的情况下, 第二次取出黑球的概率即从6黑4白中取出黑球的概率, 所以

$$P(A_2|A_1) = \frac{6}{10}$$

每个条件都可以用这样的方式计算, 由互斥事件的概率加法公式知

$$P_2 = P(A_1 A_2 B_3) + P(A_1 B_2 A_3) + P(B_1 A_2 A_3)$$

根据乘法公式可得

$$\begin{aligned}P(A_1 A_2 B_3) &= P(A_1) P(A_2|A_1) P(B_3|A_1 A_2) \\&= \frac{1}{2} \times \frac{6}{10} \times \frac{4}{10+2} = \frac{1}{10}\end{aligned}$$

同样的类似方法可得

$$\begin{aligned}P(A_1 B_2 A_3) &= \frac{4}{8} \times \frac{4}{8+2} \times \frac{6}{10+2} = \frac{1}{10} \\P(B_1 A_2 A_3) &= \frac{1}{2} \times \frac{4}{8+2} \times \frac{4+2}{10+2} = \frac{1}{10}\end{aligned}$$


所以 $P_2 = \frac{3}{10}$

1.3 贝叶斯与全概率

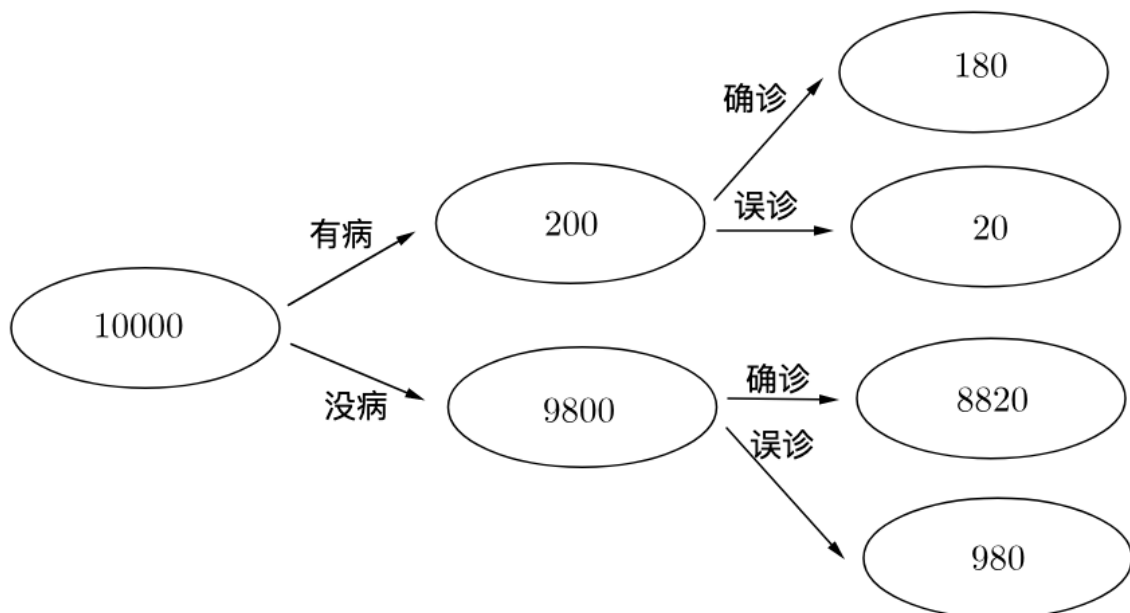
1.3.1 基本比例谬误

已知某种疾病在人群中有**2%**的患病率，可以通过某种手段来检测这种疾病，这种手段有**90%**的正确率。**90%**的正确率很高嘛，似乎被诊断出有病了之后那基本就真的有病了。真的是这样吗？


还是来画下树形图，假设有**10000**个人，**2%**的患病率就是**200**个人有病：



正确率**90%**，这个正确指的是，检测显示有病的是真有病，检测显示没病的是真没病（下图中“确诊”表示正确的诊断，“误诊”表示错误的诊断）：



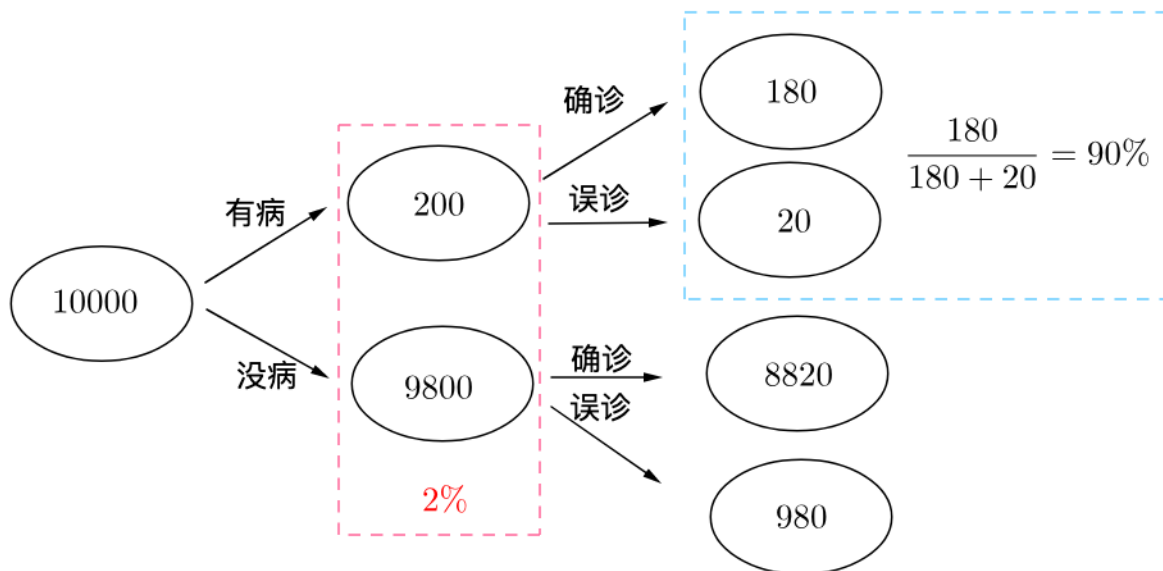
被诊断出有病包含两种可能性，一种是有病人群中的“确诊”和没病人群中的“误诊”：



也就是说这10000人里面会有 $180 + 980 = 1160$ 人被诊断有病，而真正有病的不过180人，所以如果被检测出有病，真正有病的概率只有：

$$\frac{180}{1160} \approx 15.5\%$$

根本的原因在于忽视了人群分布的基本比例，虽然确诊率高达90%，但是真正患病的人实在太少了，只占所有人中的2%：



没患病的足足有**98%**，哪怕误诊率为**10%**，但人多啊，依然有很多被误诊为有病。

这种忽视基本比例导致的错误称为**基本比例谬误** (Base Rate Fallacy) 。

1.3.2 贝叶斯

1.3.2.1 贝叶斯定理

对于随机事件 A 、 B ，若 $P(B) \neq 0$ ，有：

$$P(A|B) = \frac{P(A)}{P(B)} P(B|A)$$

解读1：在诊断问题中，已知检测的正确率有**90%**，或者说确诊率为**90%**：

$$P(B|A) = 90\%$$

而求出来的“被诊断出有病了之后真的有病的概率”为：

$$P(A|B) \approx 15.5\%$$

之前说过，差别这么大在于基本比例悬殊，也就是所有人中患者只占了**2%**，贝叶斯定理正好反映了这点：

基本比例

$$P(A|B) = \left[\frac{P(A)}{P(B)} \right] P(B|A)$$

确诊率

$P(A)$ 、 $P(B)$ 是关于所有人的概率：

$$P(A) = \text{所有人患病的概率}, \quad P(B) = \text{所有人检测显示有病的概率}$$

两者的比例就是所谓的基本比例。

解读2：贝叶斯定理除了用于解读基本比例谬误以外，还有一种更常用的解释。先把贝叶斯定理变下形：

$$P(A|B) = \frac{P(B|A)}{P(B)} P(A)$$

还是之前的疾病检测问题，还是之前定义的两个事件：

$$A = \text{“患病的人”}, \quad B = \text{“检测显示有病的人”}$$

一开始就知道人群中**有2%的患病率**，这个也称为**先验概率**（大概就是最先就知道的意思），即：

$$P(A) = 2\%$$

如果只知道这个信息，那么你患病的概率也是**2%**。但有一天去体检，检查显示你有病，这个时候相当于出现了新的信息，或者说**B条件出现了**，可以通过贝叶斯定理对患病的概率进行调整：

$$P(A|B) = \frac{P(B|A)}{P(B)} P(A)$$

B条件出现

B条件下调整的A概率


先验概率

调整的结果当然是真正有病的概率急剧上升：

$$\begin{aligned} P(A|B) &= \frac{P(B|A)}{P(B)} P(A) \\ &= \frac{0.9}{0.02 \cdot 0.9 + 0.98 \cdot 0.1} \times 0.02 \\ &\approx 15.5\% \end{aligned}$$

例题

A市有两种颜色的出租车，颜色和比例如下：



某天有一辆出租车夜间肇事后逃逸，但还好当时有一位目击证人，这位目击者认定肇事的出租车是绿色的。但是，他“目击的可信度”如何呢？公安人员经过在相同环境下对该目击者进行“蓝绿”测试而得到：**80%**的情况下识别正确，**20%**的情况不正确。

那么肇事车辆为绿色的概率有多大？

假设事件为：

$A = \text{“绿色的出租车”}$ ， $B = \text{“目击为绿色”}$

在未知的情况下，全市的出租车都有可能肇事逃逸。那么绿色出租车肇事的概率和绿色出租车的比例是一样的，也就是先验概率为：

$$P(A) = 0.1$$

这个时候目击证人出现了，他说看到的是绿色的出租车，但是警方检测之后发现他的正确率是**80%**，也就是：

$$P(B|A) = 0.8$$

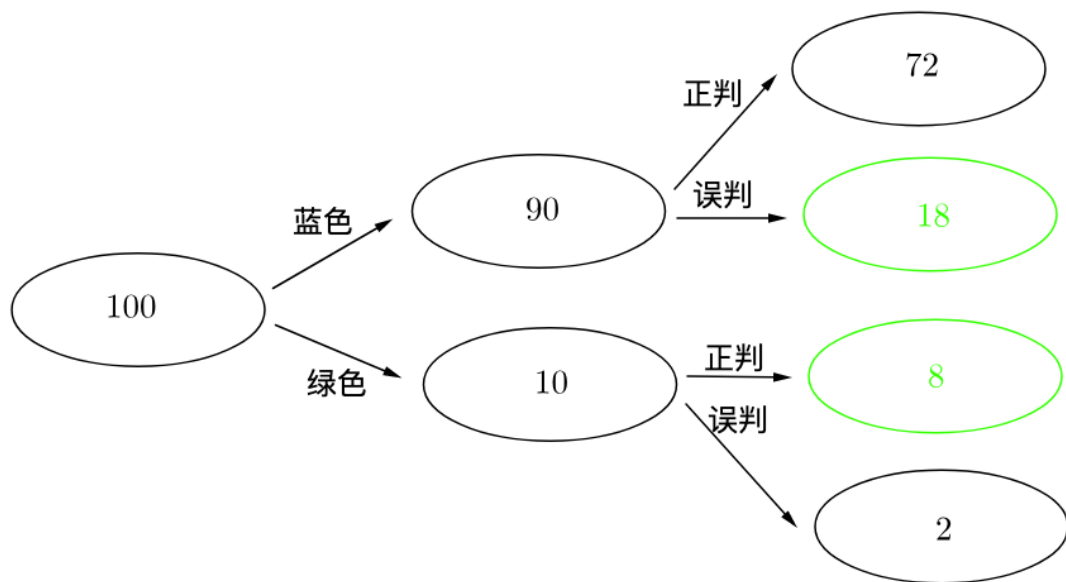
被他目击为绿色的包括绿色出租车中的**80%**、以及蓝色出租车中的**20%**，即：

$$P(B) = 0.1 \cdot 0.8 + 0.9 \cdot 0.2$$

既然目击证人有了，那么肇事车辆为绿色的概率通过贝叶斯调整后，自然会变高：

$$\begin{aligned} P(A|B) &= \frac{P(B|A)}{P(B)} P(A) \\ &= \frac{0.8}{0.1 \cdot 0.8 + 0.9 \cdot 0.2} \times 0.1 \\ &= \frac{4}{13} \end{aligned}$$

当然你也可以用树形图来解，答案也是一样的：



可以看出，哪怕有目击证人的情况下，绿色出租车作案的可能性仍然不高，因为基础比例在那里起作用，所以警察办案不能靠孤立的证据，很容易冤枉好人。

1.3.2.1 贝叶斯与修正

贝叶斯定理这种会被新的信息修正的特性特别受主观派的青睐。举个例子，比如要判断明天是否下雨，主观派说，反正一无所知就假设为**50%**吧：

$$P(A) = 50\%$$

突然发现，天边似乎有乌云，假设为事件 B_1 ，那用贝叶斯修正一下：

天边有乌云

$$\frac{P(B_1|A)}{P(B_1)} P(A)$$

主观概率

又觉得天气闷热的，假设为事件 B_2 ，再用贝叶斯修正一下：

天边有乌云

闷热

$$\frac{P(B_2|A)}{P(B_2)} \frac{P(B_1|A)}{P(B_1)} P(A)$$

主观概率

通过不断地信息修正，主观概率会越来越变得客观（对此依然有很多争论，我们无意讨论）：

$$\text{客观概率} = \frac{P(B_n|A)}{P(B_n)} \cdots \frac{P(B_2|A)}{P(B_2)} \frac{P(B_1|A)}{P(B_1)} \underbrace{P(A)}_{\text{主观概率}}$$