


### 1.4.3 全概率

#### 1.4.3.1 全概率公式

形式 (1)

设  $A_1, A_2, \dots, A_n$  为样本空间  $\Omega$  的一个分割:



用代数表示就是:

$$A_i \cap A_j = \emptyset, (i \neq j) \quad \text{且} \quad \bigcup_{i=1}^n A_i = \Omega$$

若  $P(A_i) > 0, i = 1, 2, \dots, n$ , 则对任意事件  $B$  有:

$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

形式 (2)

设  $A_1, A_2, \dots, A_n$  满足:


$$A_i \cap A_j = \emptyset, (i \neq j) \quad \text{且} \quad P\left(\bigcup_{i=1}^n A_i\right) = 1$$

若  $P(A_i) > 0, i = 1, 2, \dots, n$ , 则对任意事件  $B$  有:

$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

#### 1.4.3.2 全概率公式通俗解释

以把分割  $A_1, A_2, \dots, A_n$  看作导致  $B$  可能发生各种各样的条件:



$B$ 发生的概率可以分解到各种条件上去，这就是全概率公式的通俗解释。

#### 例题

袋中有50个乒乓球，其中20个是黄球，30个是白球，今有两人依次随机地从袋中各取一球，取后不放回，则第二个人取得黄球的概率是多少？

可以通过全概率公式来计算：

$$\begin{aligned}
 P(C) &= P(A)P(C|A) + P(\bar{A})P(C|\bar{A}) \\
 &= \frac{20}{50} \times \frac{19}{49} + \frac{30}{50} \times \frac{20}{49} \\
 &= \frac{2}{5}
 \end{aligned}$$

这个结论说明先抽、后抽对概率没有影响。

从全概率公式来看还是比较明显，全概率公式有两个分支：

- 第一个分支是**A**事件的条件下，这个时候抽黄球的概率会减小
- 第二个分支是**B**事件的条件下，这个时候抽黄球的概率会增大

两相抵消的结果就是顺序对概率没有影响。

不过如果第一个人抽完之后公示了他的结果，那么就会对第二个人的概率产生影响，这相当于只走了全概率公式中的一个分支。

### 1.4.4 贝叶斯与全概率

有了全概率公式后，可以得到贝叶斯定理真正的样子：

设 $A_1$ 、 $A_2$ 、 $\cdots$ 、 $A_n$ 为样本空间 $\Omega$ 的一个分割，则有：

$$\begin{aligned}
 P(A_i|B) &= \frac{P(BA_i)}{P(B)} \\
 &= \frac{P(B|A_i)}{P(B)} P(A_i) \\
 &= \frac{P(B|A_i)}{\sum_{i=1}^n P(A_i)P(B|A_i)} P(A_i)
 \end{aligned}$$

也就是把 $P(B)$ 分解到分割 $A_1$ 、 $A_2$ 、 $\cdots$ 、 $A_n$ 上去了。

之前已经是这么计算的了，当时没提是为了减小理解的难度。比如疾病检测问题，事件稍微重新定义下：

$A_1$  = “患病的人”，  $A_2$  = “没患病的人”，  $B$  = “检测显示有病的人”

很显然， $A_1$ 、 $A_2$ 就是一个分割，所以：

$$\begin{aligned}
 P(A_1|B) &= \frac{P(B|A_1)}{P(B)} P(A_1) \\
 &= \frac{P(B|A_1)}{P(A_1)P(B|A_1) + P(A_2)P(B|A_2)} P(A_1) \\
 &= \frac{0.02}{0.02 \cdot 0.9 + 0.98 \cdot 0.1} \times 0.9 \\
 &\approx 15.5\%
 \end{aligned}$$

#### 例题

盒中有 $a$ 个红球， $b$ 个黑球，今随机的从中取出一个，观察其颜色后放回

并加上同色球 $c$ 个，再从盒中第二次取出一球，求第二次抽出黑球的概率与第一次抽出的概率是否相同？

设

$A = \{\text{第一次抽出的是黑球}\}, B = \{\text{第二次抽出的是黑球}\}$

由题意得

$$P(A) = \frac{b}{a+b}$$

则

$$P(B|A) = \frac{b+c}{a+b+c}, P(B|\bar{A}) = \frac{b}{a+b+c}$$

因为 $A, \bar{A}$ 是样本空间的一个划分，根据全概率公式可得

$$\begin{aligned}
 P(B) &= P(A)P(B|A) + P(\bar{A})P(B|\bar{A}) \\
 &= \frac{b(b+c)}{(a+b)(a+b+c)} + \frac{ab}{(a+b)(a+b+c)} \\
 &= \frac{b}{a+b} = P(A)
 \end{aligned}$$

因此第二次抽出黑球的概率与第一次抽出的概率相同。

## 1.5 事件的独立性

### 1.5.1 严格定义

对于两个随机事件  $A$ 、 $B$ ，如果满足：

$$P(AB) = P(A)P(B)$$

则称  $A$  与  $B$  相互独立，或简称  $A$  与  $B$  独立，否则称  $A$  与  $B$  不独立或相依。

### 1.5.2 赌徒谬误

要是连续3次掷出正面，那下一次得到正面的概率有多高？



我们知道，连续出现4次正面的概率非常小：

$$\frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} = \frac{1}{16}$$

有些赌徒据此认为，已经出现3次正面了，那么下一次也得到正面的概率就非常小了。这被称为赌徒谬误。

结合已经学习过的概率论知识，可以很好的反驳这个谬误。先画一下样本空间：

第一次	第二次	第三次	第四次
<b>H</b>	<b>H</b>	<b>H</b>	<b>H</b>
H	H	H	T
H	H	T	H
H	H	T	T
H	T	H	H
H	T	H	T
H	T	T	H
H	T	T	T
T	H	H	H
T	H	H	T
T	H	T	H
T	H	T	T
T	T	H	H
T	T	H	T
T	T	T	H
T	T	T	T

可以看到，总共有16种可能性，只有第一种可能性是四次都是正面，所以投掷出四次都是正面的概率确实是 $\frac{1}{16}$ 。

投掷三次正面后，样本空间缩小了，变得只有两种可能性了（这其实是一个条件概率）：

第一次	第二次	第三次	第四次
<b>H</b>	<b>H</b>	<b>H</b>	<b>H</b>
H	H	H	<b>T</b>

所以第四次为正面的概率依然为 $\frac{1}{2}$ 。

### 1.5.3 多个事件的独立性

三个事件

$$\text{设 } A、B、C \text{ 是三个事件，如果满足：} \begin{cases} P(AB) = P(A)P(B) \\ P(BC) = P(B)P(C) \\ P(AC) = P(A)P(C) \end{cases} \quad (1)$$

则称  $A、B、C$  是两两独立。若还有：

$$P(ABC) = P(A)P(B)P(C) \quad (2)$$

则称  $A$ 、 $B$ 、 $C$  三者相互独立。

### 多个事件

设  $A_1$ 、 $A_2$ 、 $\dots$  为有限个或者无限个事件，从中任取两个  $A_{i1}$ 、 $A_{i2}$ ，若满足：

$$P(A_{i1} A_{i2}) = P(A_{i1})P(A_{i2})$$

则称  $A_1$ 、 $A_2$ 、 $\dots$  是两两独立。

若从中任取有限个  $A_{j1}$ 、 $A_{j2}$ 、 $\dots$ 、 $A_{jm}$ ，若满足：

$$P(A_{j1} A_{j2} \cdots A_{jm}) = P(A_{j1})P(A_{j2}) \cdots P(A_{jm})$$

则称  $A_1$ 、 $A_2$ 、 $\dots$  是相互独立。

很显然：

$$\text{相互独立} \implies \text{两两独立}$$

而比较反直觉的是：

$$\text{相互独立} \not\Leftarrow \text{两两独立}$$

### 例题

有两名选手比赛射击，轮流对同一目标进行射击，甲命中目标的概率为  $\alpha$ ，乙命中目标的概率为  $\beta$ 。甲先射，谁先命中谁得胜。

问：甲获胜的概率是多少

记事件  $A_i$  为“第  $i$  次射击命中目标”， $i = 1, 2, \dots$ 。因为甲先射，所以事件“甲获胜”可以表示为

$$A_1 \cup \bar{A}_1 \bar{A}_2 A_3 \cup \bar{A}_1 \bar{A}_2 \bar{A}_3 \bar{A}_4 A_5 \cup \dots$$

又因为各次射击是独立的，所以得

$$P\{\text{甲获胜}\} = \alpha + (1 - \alpha)(1 - \beta)\alpha + (1 - \alpha)^2(1 - \beta)^2\alpha + \dots$$

$$= \alpha \sum_{i=0}^{\infty} (1 - \alpha)^i (1 - \beta)^i$$

根据等比数列求和，得

$$\text{原式} = \alpha \lim_{n \rightarrow \infty} \frac{1 - [(1 - \alpha)(1 - \beta)]^n}{1 - (1 - \alpha)(1 - \beta)}$$

根据题意有  $0 < (1 - \alpha)(1 - \beta) < 1$ ，所以

$$\text{原式} = \frac{\alpha}{1 - (1 - \alpha)(1 - \beta)}$$

## 2 随机变量及其分布

### 2.1 随机变量

#### 2.1.1 随机变量的定义

定义在样本空间 $\Omega$ 上的实值函数：

$$X = X(\omega), \quad \omega \in \Omega$$

称为随机变量。

随机变量是一个函数，所以都用大写字母来表示，以示和自变量 $x$ 的区别。

进一步规定，“随机变量 $X$ 的取值为 $x$ ”就是满足等式 $X(\omega) = x$ 的一切 $\omega$ 组成的集合，简记为“ $X = x$ ”，这是 $\Omega$ 的一个子集，即：

$$“X = x” = \{\omega : X(\omega) = x\} \subset \Omega$$

类似地，有：

$$“X \leq x” = \{\omega : X(\omega) \leq x\} \subset \Omega$$

#### 2.1.2 引入随机变量的意义

数学最重要的特征就是抽象，引入随机变量就是《概率论与数理统计》这门课程进行抽象的重要步骤。


之后，本课程就主要研究随机变量以及相应的概率函数，并且只需要研究有限的类别，就可以覆盖生活、生产中大部分的需要。

#### 2.1.3 随机变量的离散与连续


对于随机变量：

$$X = X(\omega), \quad \omega \in \Omega$$

如果随机变量的函数值是实数轴上孤立的点（有限个或者无限个），则称为离散随机变量：



如果随机变量的函数值是实数轴上某个区间上所有的值（也可以是 $(-\infty, +\infty)$ 区间），则称为连续随机变量：



## 2.2 二项分布

### 2.2.1 概率质量函数

有了随机变量之后，我们对概率的研究就变成了对一个个函数的研究。

#### 2.2.1.1 概率质量函数定义

设 $X$ 为离散型随机变量，其全部可能值为 $x_1, x_2, \dots$ ，则：

$$p_i = p(x_i) = P(X = x_i), \quad (i = 1, 2, \dots)$$

称为 $X$ 的 **概率质量函数** (Probability Mass Function, 缩写为PMF) 。

上式还可写作列表的形式：

$X$	$x_1$	$x_2$	$x_3$	$\dots$
$P$	$p(x_1)$	$p(x_2)$	$p(x_3)$	$\dots$

所以也称为 $X$ 的 **概率分布列**，或者简称为 **概率分布**。

有时候也如下表示：

$$X \sim p(x)$$

读作 $X$ 服从 $p(x)$ 的概率分布。

#### 2.2.1.2 概率质量函数严格定义

如果 $p(x)$ 满足 ( $x \in \{x_i\}, i = 1, 2, \dots$ )：

- 非负性：

$$p(x_i) \geq 0$$

- 规范性：

$$\sum_{i=1}^{\infty} p(x_i) = 1$$

则称其为概率质量函数 (PMF) 。

这两个性质决定了随机变量 $X$ 不能随便选取。



### 2.2.2 伯努利分布

某样本空间只包含两个元素， $\Omega = \{\omega_1, \omega_2\}$ ，在其上定义随机变量 $X$ ：

$$X = X(\omega) = \begin{cases} 1, & \omega = \omega_1 \\ 0, & \omega = \omega_2 \end{cases}$$

若 $0 \leq p \leq 1$ 时，有：

$$\begin{aligned} p(1) &= P(X = 1) = p \\ p(0) &= P(X = 0) = 1 - p \end{aligned}$$

或写作：

$$P(X = x) = p(x) = \begin{cases} p, & x = 1 \\ 1 - p, & x = 0 \end{cases}$$

则此概率分布称作**0 - 1分布**，也称作**伯努利分布**，用以纪念数学家雅各布·伯努利。

### 2.2.3 n重伯努利试验

在数学中，类似于扔一次硬币这样的“是非题”称为一次**伯努利试验**，像上面这样独立地重复扔 **$n$** 次硬币（做同样的“是非题” **$n$** 次），就称为 **$n$ 重伯努利试验**。

注意，这里强调了要**独立**，也就是第 **$n$** 次扔硬币的概率不会受到前面的影响。

### 2.2.4 二项分布的定义

对于 **$n$** 重伯努利实验，如果每次得到“是”的概率为 **$p$** ，设随机变量：

$$X = \text{得到“是”的次数}$$

则称：

$$p(k) = P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n$$

为随机变量 $X$ 的**二项分布**，也可以记作：

$$X \sim b(n, p)$$

当 **$n = 1$** 的时候，对应的就是伯努利分布，所以伯努利分布也可以记作 **$b(1, p)$** 。

### 2.2.5 离散的累积分布函数

设 $X$ 是一个随机变量， $x$ 是任意实数，函数：

$$F(x) = P(X \leq x) = \sum_{a \leq x} p(a)$$

因为是把概率分布函数累加起来，所以称为**累积分布函数**（Cumulative Distribution Function，或者缩写为CDF），也简称为**分布函数**。

在这里，定义累积分布函数主要是为了计算上的便利，以下常见计算都可以CDF来完成：

$P(X \leq a)$	$F(a)$
$P(X > a)$	$1 - F(a)$
$P(a_1 < X \leq a_2)$	$F(a_2) - F(a_1)$

作为例子，我们来看看伯努利分布的累积分布函数：

已知伯努利分布的PMF为：

$$p(x) = \begin{cases} p, & x = 1 \\ 1 - p, & x = 0 \end{cases}$$

那么根据定义容易得到伯努利分布的CDF为：

$$F(x) = \begin{cases} 0, & x < 0 \\ 1 - p, & 0 \leq x < 1 \\ 1, & x \geq 1 \end{cases}$$

同样的，根据定义，二项分布的CDF为：

$$F(x) = \sum_{k \leq x} \binom{n}{k} p^k (1-p)^{n-k}$$

#### 例题

预定餐厅座位而不来就餐的顾客比例为20%，

如今餐厅有3个座位，但预留给了5位顾客，问到时来到餐厅而没有座位的概率是多少？

设 $X$ 表示到时来到餐厅的顾客人数，有 $X$ 服从二项分布，根据题意有

$$X \sim b(5, 0.8)$$

故所求概率为

$$\begin{aligned} P(X \geq 4) &= P(X = 4) + P(X = 5) \\ &= \binom{5}{4} \times 0.8^4 \times 0.2 + 0.8^5 = 0.73728 \end{aligned}$$

## 2.3 离散的数学期望

### 2.3.1 期望的定义

设离散随机变量 $X$ 的概率质量函数为：

$$p(x_i) = P(X = x_i), i = 1, 2, \dots, n, \dots$$

如果：

$$\sum_{i=1}^{\infty} |x_i| p(x_i) < \infty$$

则称：

$$E(X) = \sum_{i=1}^{\infty} x_i p(x_i)$$

为随机变量 $X$ 的数学期望 (expected value, 或, expectation) , 简称期望或均值 (mean) , 也有很多文档会用 $\mu_X$ 来表示 (如果不强调随机变量的话, 也可以直接用 $\mu$ 来表示) :

$$\mu_X = \mu = \sum_{i=1}^{\infty} x_i p(x_i)$$

若级数 $\sum_{i=1}^{\infty} |x_i| p(x_i)$ 不收敛, 则称 $X$ 的数学期望不存在。

## 2.3.2 矩

不管是“不确定性的计量”还是“加权平均”, 都可以通过力矩来解释, 所以数学期望也称作矩, 更准确点说, 由于数学期望:

$$E(X) = \sum_{i=1}^{\infty} x_i p(x_i)$$

中 $x_i$ 是一次项, 所以又称作一阶矩。这个称呼经常在统计的书上会遇到, 特在此说明。

## 2.3.3 期望的性质

### 2.3.3.1 复合

假设 $g(X)$ 为随机变量 $X$ 的某一函数, 则:

$$E[g(X)] = \sum_i g(x_i) p(x_i)$$

### 2.3.3.2 常数

若 $c$ 为常数, 则:

$$E(c) = c$$

### 2.3.3.3 线性组合

数学期望满足:

- 齐次性, 对于任意常数 $a$ 有:

$$E(aX) = aE(X)$$

- 可加性，对于随机变量的函数 $g_1(X)$ 、 $g_2(X)$ 有：

$$E[g_1(X) + g_2(X)] = E[g_1(X)] + E[g_2(X)]$$

### 2.3.4 二项分布的期望

伯努利分布和二项分布的期望分别如下：

	伯努利分布	二项分布
$PMF$	$p(x) = \begin{cases} p, & x = 1 \\ 1 - p, & x = 0 \end{cases}$	$p(x) = \binom{n}{x} p^x (1 - p)^{n-x}$
$\mu$	$p$	$np$

收起详细

(1) 伯努利分布的期望可以如下计算：

$$\mu = 1 \times p + 0 \times (1 - p) = p$$

(2) 二项分布的期望可以如下计算：

$$\mu = \sum_{x=0}^n xp(x) \qquad x = 0 \text{ 时 } xp(x) = 0$$

$$= \sum_{x=1}^n x \binom{n}{x} p^x (1 - p)^{n-x} \qquad \binom{n}{x} = \frac{n}{x} \binom{n-1}{x-1}$$

$$= np \sum_{x=1}^n \binom{n-1}{x-1} p^{x-1} (1 - p)^{n-x}$$

$$= np(p + 1 - p)^{n-1} = np$$

从这里也可以看出，伯努利分布是二项分布的特例。

### 2.3.5 辛普森悖论

下面是对美国某大学的两个学院的招生情况进行的一个统计，首先是法学院：

性别	录取	拒收	总数	录取比例
男生	8	45	53	15.1%
女生	51	101	152	33.6%
合计	59	146	205	28.8%

然后是商学院：

性别	录取	拒收	总数	录取比例
男生	201	50	251	80.1%
女生	92	9	101	91.1%
合计	293	59	352	83.2%


在这两个表格中，女生的录取比例都更高，这个时候我们往往会认为总体的录取比例就是女生更高。现在将两学院的数据汇总：

性别	录取	拒收	总数	录取比例
男生	209	95	304	68.8%
女生	143	110	253	56.5%
合计	352	205	557	63.2%


汇总之后，男生的录取比率反而更高，与我们的直觉相反。这就是 辛普森悖论。

悖论的向量观点

这里再简单介绍一种理解辛普森悖论的向量观点，数学是抽象的，多一些视角总是有助于融会贯通的。  
首先把法学院的男生招生情况组成一个向量：（招生总数，录取人数）。这个向量的斜率就是法学院男生的录取比例：



同理，商学院的男生招生情况可以组成另外一个向量，斜率就是商学院男生的录取比例：




商学院

性别	录取	总数	录取比例
男生	201	251	80.1%
女生	92	101	91.1%
合计	293	352	83.2%

这两个向量相和构成一个新的向量：

$$\mathbf{c} = \mathbf{a} + \mathbf{b} = \begin{pmatrix} 304 \\ 209 \end{pmatrix}$$


根据向量加法的三角形法则， $\mathbf{c}$ 正好与 $\mathbf{a}$ 、 $\mathbf{b}$ 组成一个三角形，斜率为汇总之后的男生录取率：



汇总表

性别	录取	总数	录取比例
男生	209	304	68.8%
女生	143	253	56.5%
合计	352	557	63.2%

女生的录取情况同样可以用一个三角形来表示（ $\mathbf{a}'$ 表示法学院女生， $\mathbf{b}'$ 表示商学院女生， $\mathbf{c}'$ 表示汇总女生），把这两个三角形放在一起：



汇总表

性别	录取	总数	录取比例
男生	209	304	68.8%
女生	143	253	56.5%
合计	352	557	63.2%

可以看到，虽然  $a'$ 、 $b'$  的斜率大于  $a$ 、 $b$ ，但是最终  $c$  的斜率却大于  $c'$ ，这就是辛普森悖论的几何意义。